IA048 – Aprendizado de Máquina

Atividade 3 – Redes Neurais Artificiais: MLPs e CNNs

Turma A – 2º semestre de 2026

Prof: Levy Boccato Email: lboccato@unicamp.br

Introdução

Nesta atividade, vamos abordar o problema de reconhecimento de células sanguíneas periféricas utilizando a base de dados BloodMNIST [Acevedo et al., 2020, Yang et al., 2021] (https://medmnist.com/), a qual possui 17.092 imagens microscópicas coloridas (3 canais de cor). A Figura 1 exibe uma amostra de cada classe existente na base de dados considerando a versão com resolução de 28×28 pixels. O mapeamento entre os identificadores das classes e os rótulos está indicado na Tabela 1.

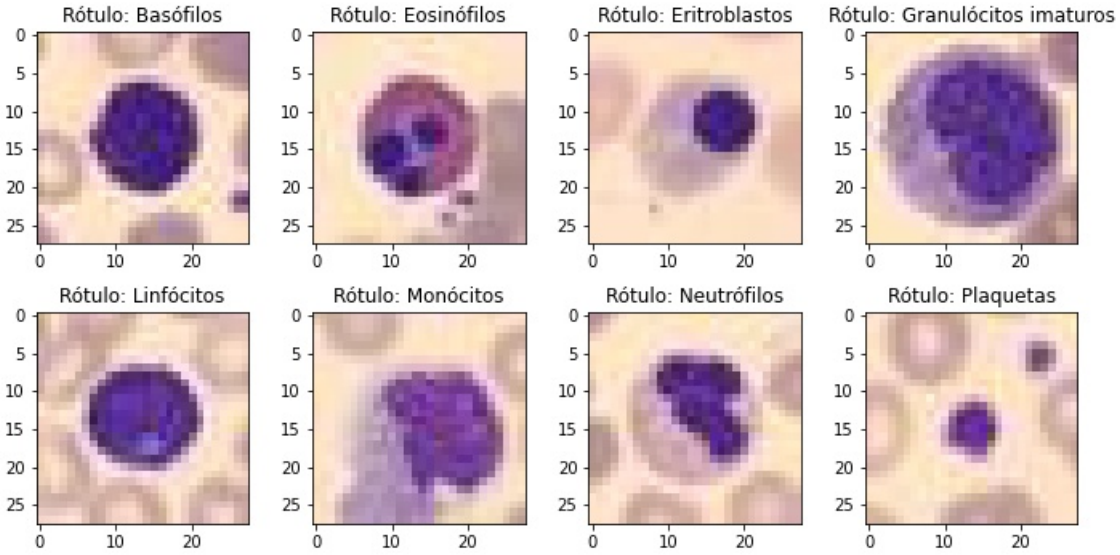


Figura 1: Amostras da base de dados BloodMNIST.

Id	Rótulo
0	Basófilos
1	Eosinófilos
2	Eritroblastos
3	Granulócitos imaturos
4	Linfócitos
5	Monócitos
6	Neutrófilos
7	Plaquetas

Tabela 1: Correspondência entre os identificadores numéricos das classes e os tipos de células sanguíneas.

Atividades

(a) Aplique uma rede MLP com uma camada intermediária e analise (1) a acurácia balanceada, (2) a F_1-medida e (3) a matriz de confusão para os dados de teste obtidas pela melhor versão desta rede. Descreva a metodologia e a arquitetura empregada, bem como todas as escolhas feitas.

(b) Monte uma CNN simples contendo: (*i*) uma camada convolucional com função de ativação não-linear; (*ii*) uma camada de *pooling*; (*iii*) uma camada de saída do tipo *softmax*. Avalie a progressão da acurácia balanceada junto aos dados de validação em função:

- Da quantidade de *kernels* utilizados na camada convolucional;
- Do tamanho do *kernel* de convolução.

(c) Escolhendo, então, a melhor configuração para a CNN simples, refaça o treinamento do modelo e apresente:

- A matriz de confusão para os dados de teste;
- A acurácia balanceada e a F_1-medida;
- Cinco padrões de teste que foram classificados incorretamente, indicando a classe esperada e as probabilidades estimadas pela rede.

Discuta os resultados obtidos.

(d) Utilize, agora, uma CNN bem estabelecida na literatura e cujos pesos pré-treinados na ImageNet estejam disponíveis (*e.g.*, utilizando a biblioteca `torchvision.models`). Após adaptar a parte de saída da rede, faça o treinamento (com validação cruzada) e analise o desempenho no conjunto de teste considerando algumas métricas globais e a matriz de confusão.

Faça, por fim, uma comparação geral entre os três modelos considerados - MLP, CNN artesenal e CNN com *transfer learning* -, tendo em vista o desempenho, a quantidade de parâmetros de cada modelo e o tempo consumido na fase de treinamento.

Observações: No relatório, não é necessário descrever a teoria sobre as redes neurais utilizadas. Não obstante, todas as escolhas feitas com respeito às características dos modelos, dos dados e dos experimentos devem ser apresentadas e justificadas, de modo a possibilitar o entendimento e a reprodução da metodologia.

Referências

[Yang et al., 2021] J. Yang, R. Shi, D. Wei, z. Liu, L. Zhao, B. Ke, H. Pfister, B. Ni, *MedMNIST v2: A Large-Scale Lightweight Benchmark for 2D and 3D Biomedical Image Classification*. arXiv preprint arXiv:2110.14795, 2021.

[Acevedo et al., 2020] A. Acevedo, A. Merino, S. Alférez, A. Molina, L. Boldú, J. Rodellar, *A dataset of microscopic peripheral blood cell images for development of automatic recognition systems*, Data in Brief, vol. 30, 2020.